

IIIII Organizzazioni hash dinamiche

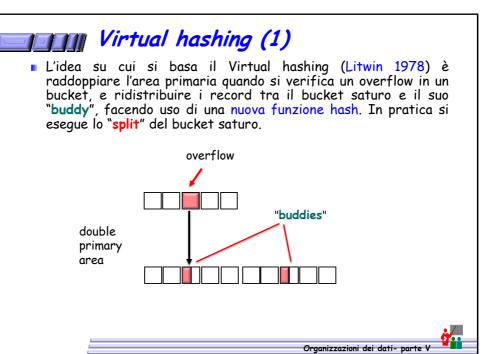
- Il limite principale delle organizzazioni hash statiche riguarda l'allocazione (statica) dell'area primaria. Nel caso di archivi (fortemente) dinamici un'allocazione statica è inadeguata, a causa o dell'eccessivo spreco di memoria (bassa utilizzazione) o del deterioramento delle prestazioni (alta utilizzazione). Inoltre, nel caso di overflow gestiti in area primaria, si ha il vincolo d ≤ 1.
- Le organizzazioni hash dinamiche non presentano questi problemi, in quanto adattano l'allocazione dell'area primaria alla dimensione corrente dell'archivio.
- Esistono due grandi categorie di organizzazioni hash dinamiche:
 - **★**con direttorio (struttura ausiliaria), tra cui:

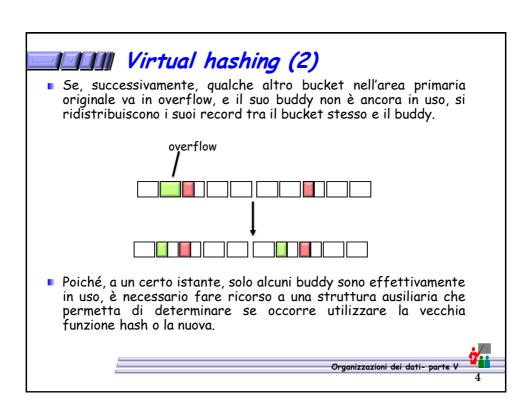
Virtual hashing, Dynamic Hashing, Extendible Hashing

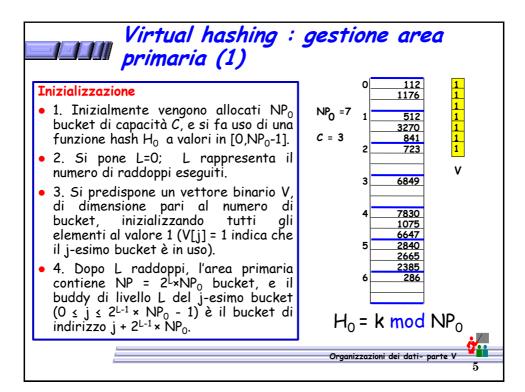
≠senza direttorio, tra cui:

Linear Hashing, Spiral Hashing







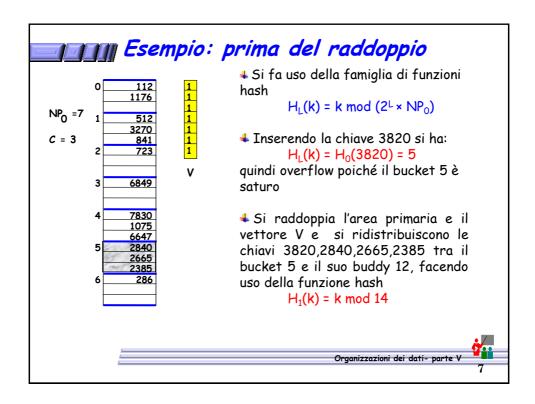


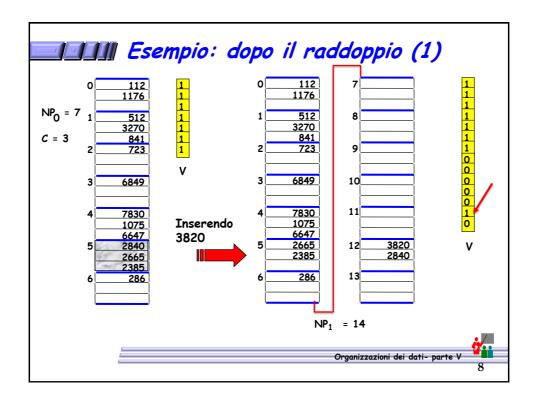
Virtual hashing : gestione area primaria (2)

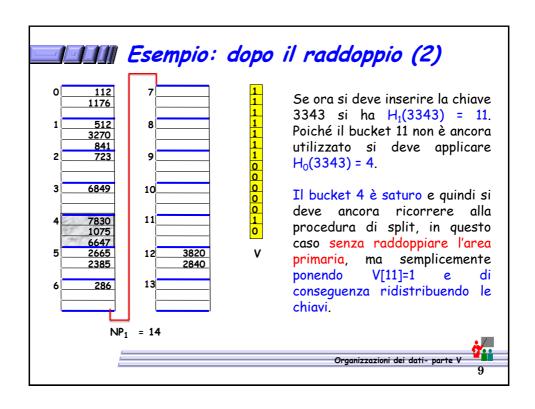
Split di un bucket

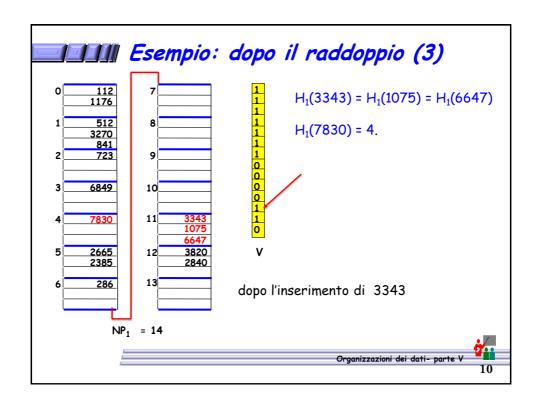
- 5. In caso di overflow del bucket j:
- 5.1 Se L = 0, oppure L > 0 ma il buddy di livello L è già in uso o non esiste (L > 0, ma $V[j + 2^{L-1} \times NP_0] = 1$ o $j \ge 2^{L-1} \times NP_0$)
 - 5.1.1 Si incrementa L, si raddoppia l'area primaria il vettore V; i nuovi elementi di V valgono O, eccetto V[j + 2^{L-1} × NP₀].
 - >5.1.2 Si introduce la nuova funzione hash H_L a valori nell'intervallo [0, $2^L \times NP_0$ -1].
 - > 5.1.3 Si ridistribuiscono le chiavi del bucket j facendo uso della funzione H₁.
- 5.2 altrimenti
 - > 5.2.1 Si determina il buddy di livello minimo r (1 ≤ r ≤ L) non ancora in uso $(V[j + 2^{r-1} \times NP_0] = 0)$.
 - > 5.2.2 Si pone $V[j+2^{r-1} \times NP_0] = 1$.
 - ➤ 5.2.3 Si ridistribuiscono le chiavi del bucket j facendo uso della funzione H_r.

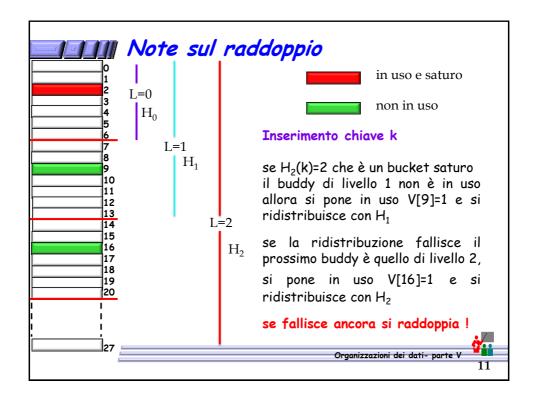
Organizzazioni dei dati- parte V











IIIII Virtual hashing: funzioni hash

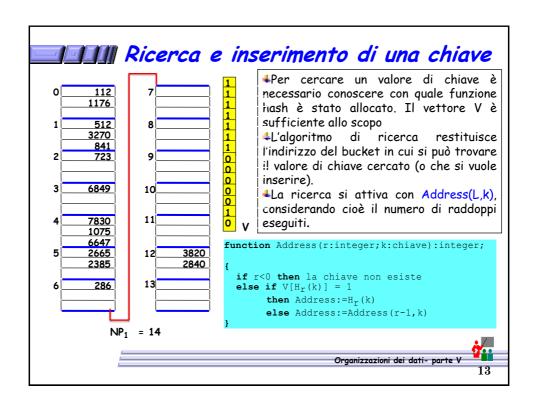
- Il virtual hashing richiede una serie di funzioni hash H₀, H₁, ..., H₁,... che soddisfino le seguenti condizioni:
- * Range condition La funzione H_L deve essere a valori in [0, $2^L \times NP_0$ -1].
- **♣** Split condition

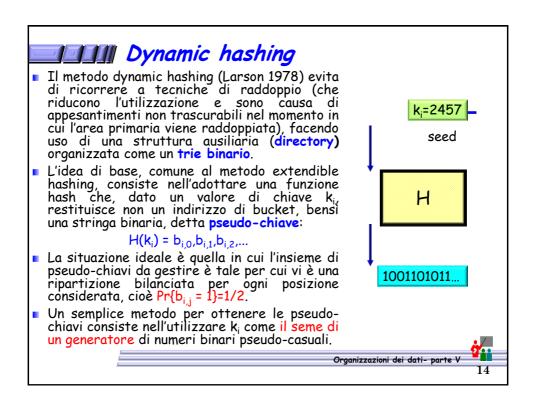
Per ogni L > 0, per ogni valore di chiave k, e per ogni valore di $H_L(k)$, deve valere la relazione:

 $H_L(k) = H_{L-1}(k)$ oppure $H_L(k) = H_{L-1}(k) + 2^{L-1} \times NP_0$ ovvero lo split di un bucket deve lasciare una chiave nel bucket stesso, o allocarla nel buddy.

■ La famiglia di funzioni $H_L(k)$ = k mod $(2^L \times NP_0)$ evidentemente soddisfa la prima condizione; si dimostra che soddisfa anche la condizione di split.

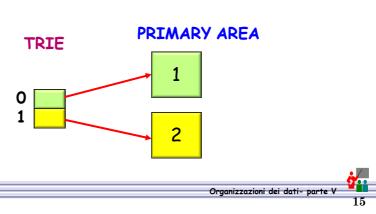


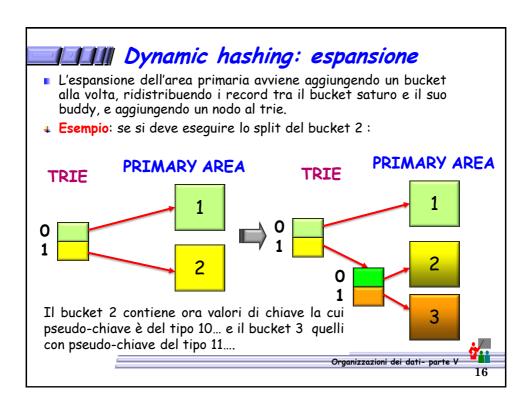




IDIII Dynamic hashing: uso del trie

- Il trie serve a organizzare la ricerca, e i suoi nodi foglia indirizzano i bucket dell'area dati. Per cercare (o inserire) un valore di chiave si segue, fino a una foglia, il cammino del trie corrispondente alla pseudo-chiave.
- Esempio: il bucket 1 contiene tutti i valori di chiave la cui pseudo-chiave è del tipo 0...., e il bucket 2 quelli con pseudochiave 1...

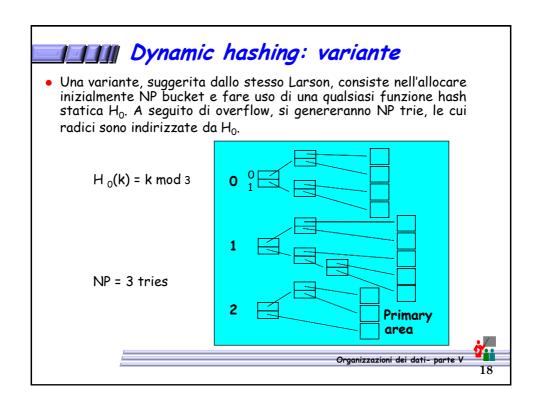




<u> IIIII</u> Dynamic hashing: prestazioni

- Se il trie è in memoria centrale è sufficiente un singolo accesso per recuperare un record, altrimenti le prestazioni dipendono dal bilanciamento, in termini di numero di nodi indice da reperire.
- Le prestazioni nel caso peggiore non sono buone. Infatti, dipendentemente dall'insieme di pseudo-chiavi, l'inserimento di un nuovo record può comportare più di uno split.
- Se dopo una cancellazione in un bucket, il numero di record contenuti nel bucket e nel suo buddy diventa minore o uguale alla capacità C, i bucket vengono fusi, e si elimina un nodo foglia dal trie.
- L'utilizzazione media è di circa il 70%.





IIIII Extendible hashing

- Extendible hashing (Fagin, Nievergelt, et al. 1979) è un'organizzazione molto simile al dynamic hashing, da cui si differenzia per il modo con cui gestisce il direttorio.
- Garantisce il reperimento di un record con non più di due accessi alla memoria secondaria.
- **4** Il direttorio è un insieme di 2^p celle che hanno indirizzi nell'intervallo $[0,2^p-1]$ e p ≥ 0 è detta *profondità* del direttorio.
- Una funzione hash associa a ogni chiave una pseudo-chiave binaria,

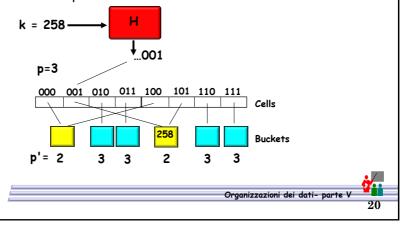
$$H(k_i) = ..., b_{i,2}, b_{i,1}, b_{i,0}$$

di cui si considerano i p bit meno significativi per accedere *direttamente* a una delle 2^p celle, ognuna contenente un puntatore a un bucket.

Organizzazioni dei dati- parte V

Extendible hashing: direttorio

- Ogni bucket ha una profondità locale p' ≤ p (valore mantenuto nel bucket) che indica il numero effettivo di bit usati per allocare le chiavi nel bucket stesso.
- Esempio: Il bucket che contiene la chiave 258 ha p' = 2. Pertanto contiene sia chiavi con pseudo-chiave del tipo ...001 sia chiavi con pseudo-chiave del tipo ...101.



IMMI Extendible hashing: split

Inizialmente si ha un solo bucket, p' = 0 e p = 0.
Se si deve eseguire lo split di un bucket a profondità locale p', si presentano 2 casi:

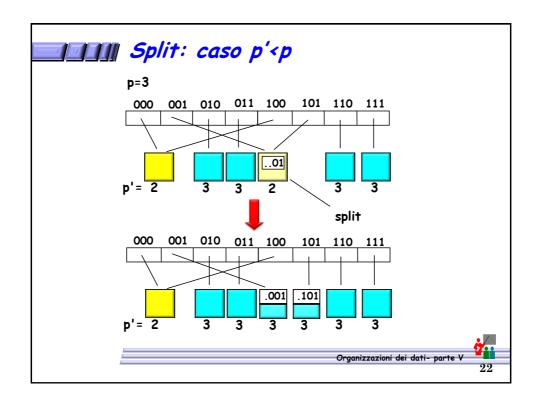
p' < p

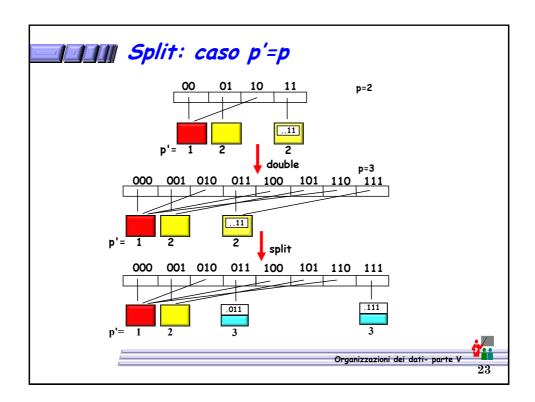
- ≠si alloca un nuovo bucket e si distribuiscono le chiavi tra i due bucket facendo uso del (p'+1)-esimo bit delle pseudo-chiavi. Per i due bucket si pone a p'+1 il valore della profondità locale.
- poiché p' < p, esiste almeno una cella che può indirizzare il nuovo bucket. Si modifica pertanto il puntatore della/e cella/e.

p' = p

- si raddoppia il direttorio, e si incrementa p di 1. Si copiano i valori dei puntatori nelle nuove celle corrispondenti
- ≠si esegue lo split come nel caso p' < p.



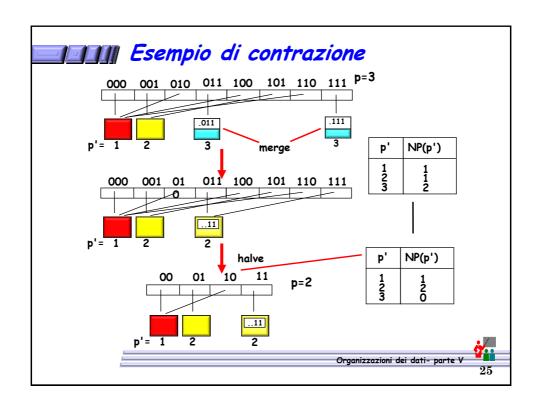


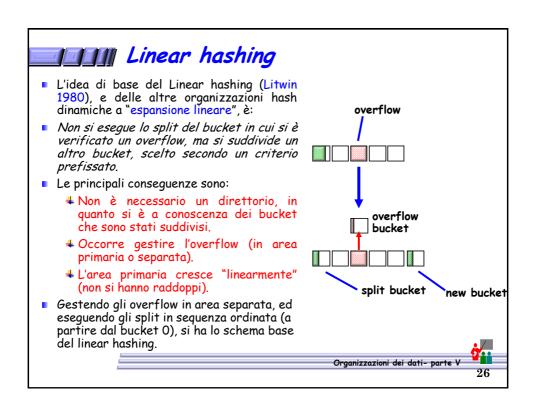


INTILI Contrazione del direttorio

- Se si cancella un record in un bucket a profondità p', e il numero di record contenuti nel bucket e nel suo buddy diventa minore o uguale alla capacità C, i bucket vengono fusi. Per il bucket risultante la profondità locale vale p'-1.
- Se si fondono gli unici due bucket a profondità p' = p, è possibile contrarre il direttorio, dimezzandolo.
- Poiché verificare che non esistono più bucket a profondità p richiede, nel caso peggiore, di esaminare metà dei bucket, è conveniente fare uso di una tabella delle profondità locali che, per ogni valore p' ≤ p, mantiene il numero, NP(p'), di bucket a profondità p'.







| | | | Gestione area primaria (1)

- ♣ Inizialmente si allocano NP₀ bucket e si usa la funzione $H_0(k) = k \mod NP_0$ hash
- ♣ Si mantiene un puntatore (detto split pointer, SP) al prossimo bucket che deve essere suddiviso. Inizialmente SP = 0.
- Se si verifica un overflow si aggiunge in coda un bucket di indirizzo NP₀ + SP, si riallocano i record del bucket SP (inclusi quelli eventualmente presenti in area di overflow) facendo uso della nuova funzione hash:

```
H_1(k) = k \mod (2 \times NP_0) e si incrementa SP (= SP + 1).
```

♣ Dopo NP₀ overflow si è operata un'*espansione completa* dell'area primaria, in quanto il numero di bucket è ora pari a $2 \times NP_0$.



🔟 🎹 Gestione area primaria (2)

Dopo un'espansione completa, ci si predispone per una nuova espansione ponendo

```
H_0(k) = H_1(k) H_1(k) = k \mod (2^2 \times NP_0).
```

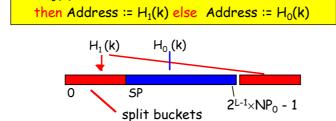
Durante la L-esima espansione si fa uso delle funzioni hash

$$H_0(k) = k \mod (2^{L-1} \times NP_0).$$

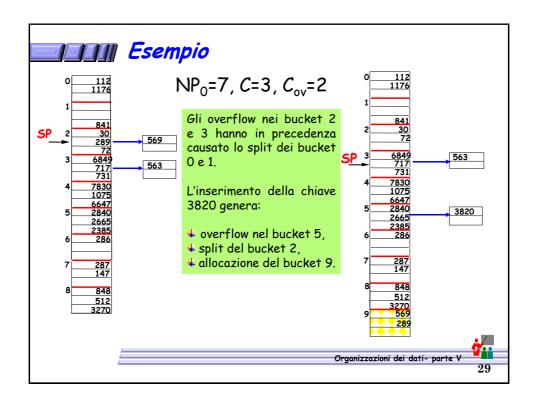
 $H_1(k) = k \mod (2^L \times NP_0).$

if Ho(k) SP

e l'indirizzo dell'home bucket di una chiave si calcola come:



Organizzazioni dei dati- parte V



______Linear hashing: pregi e difetti

■ Pregi

- L'assenza di un direttorio e la politica di gestione degli split rendono semplice la realizzazione della struttura.
- La gestione dell'area primaria (espansione e contrazione) è immediata, in quanto i bucket vengono sempre aggiunti (e rimossi) in coda.

Difetti

♣L'utilizzazione della memoria allocata, data da:

$$u = \frac{NR}{C \times NP + C_{ov} \times NP_{ov}}$$

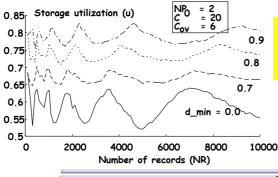
è decisamente bassa (variabile tra 0.5 e 0.7);

- La gestione dell'area di overflow presenta problemi simili a quelli di un'area primaria statica.
- Le catene di overflow relative ai bucket di indirizzo maggiore, non ancora suddivisi, possono diventare molto lunghe.

Organizzazioni dei dati- parte V

💶 👊 Linear hashing: utilizzazione

- * Rispetto alla versione di base, che esegue lo split ogni qualvolta si verifica un overflow, sono possibili le seguenti varianti:
- Controllo del carico: dopo la fase iniziale di caricamento negli NP₀ bucket, gli split avvengono ogni L inserimenti.
- * Split controllato: si esegue lo split solo quando il fattore di caricamento, d, raggiunge un valore di soglia d_min (es. d_min = 0.8).



Ciclicità del linear hashing: i casi peggiori si verificano a 1/3 ÷ 2/3 di un'espansione completa

v

Organizzazioni dei dati- parte V

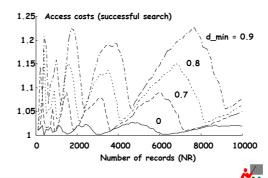
31

Mana Costi di accesso

- All'aumentare dell'utilizzazione di memoria aumentano anche i costi di ricerca, in quanto tende ad aumentare il numero di record in overflow. Risultati qualitativamente simili si ottengono anche nel caso di ricerca con insuccesso.
- Anche per i costi di accesso si può osservare come le prestazioni dipendano dal valore specifico di NR e, quindi, di NP.

Si noti tuttavia che, a parità di d_min, i costi di accesso diminuiscono all'aumentare dell'utilizzazione di memoria, e viceversa, come facilmente rilevabile dal confronto dei due grafici relativi.

Esempio: per NR ≈ 5000 e d_min = 0 si ha un minimo relativo dell'utilizzazione e un massimo relativo dei costi di accesso.



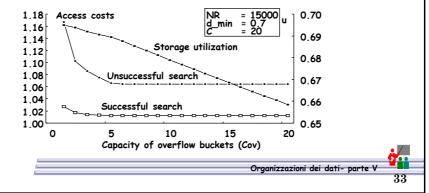
Organizzazioni dei dati- parte V

32

💶 👊 Capacità bucket di overflow

 Litwin fornisce, come indicazione pratica per la scelta della capacità dei bucket di overflow un valore pari a

■ Aumentare C_{ov} riduce la lunghezza (in bucket) delle catene di overflow, ma questa lunghezza non può comunque essere minore di 1 (se vi sono overflow). Pertanto oltre un certo valore si ha solo un inutile spreco di memoria.



Varianti del linear hashing

- Linear hashing con espansioni parziali (Larson 1980, Ramamohanarao & Lloyd 1982).
 - ♣ la tecnica parte dalla considerazione che un bucket già suddiviso contiene, in media, un numero di record pari alla metà di quello contenuto in un bucket ancora da dividere. Ciò porta a una bassa utilizzazione della memoria e a una distribuzione degli overflow non uniforme. L'idea di base delle tecniche di espansione parziale è anticipare gli split, dividendo un "gruppo" di più bucket alla volta.
- Linear hashing ricorsivo (Ramamohanarao & Sacks-Davis 1984)
 - La caratteristica principale riguarda la gestione dell'area di overflow, che è organizzata dinamicamente facendo uso del Linear hashing stesso. Si creano vari livelli di file hash dinamici (in media non più di 3), con il file al livello h (h = 0,..,L; h = 0 area primaria) che memorizza i suoi overflow nel file a livello h + 1. Al livello h si mantiene lo split pointer SPh.



IIII Spiral hashing

Con il linear hashing c'è una maggiore probabilità di avere overflow dai blocchi non ancora suddivisi durante l'espansione corrente; infatti, l'uso di una funzione hash uniforme ha come conseguenza che ogni valore di H₀(k) è ugualmente probabile, ma i bucket per cui si ha H₀(k) < SP sono già stati suddivisi. La tecnica spiral hashing (Martin '79) cerca di risolvere questo problema impiegando una funzione di tipo esponenziale, che consente di memorizzare i record più densamente nell'estremo iniziale dell'area primaria.</p>

L'organizzazione deve il suo nome (e quello di alcuni suoi parametri) al fatto che lo spazio di memoria viene pensato come una spirale, invece che come una retta, e l'area primaria come una rivoluzione della spirale, univocamente definita da un angolo z.





3.5